

پروژه UniDB

طراحی موتور دیتابیس NoSQL

فاز اول

ساختمان داده‌ها

دکتر افسانه فاطمی

پاییز ۱۴۰۴

تاریخ تحویل:

۱۴۰۴/۰۹/۲۱

مباحث تحت پوشش

آرایه‌ها، لیست‌های پیوندی، پشته، صف، تحلیل پیچیدگی، معماری لایه‌ای

مقدمه

در این پروژه، شما هسته مرکزی یک دیتابیس NoSQL شبیه MongoDB را پیاده‌سازی می‌کنید. تمرکز اصلی پروژه علاوه بر تمرین ساختمان داده‌ها، رعایت **معماری تمیز (Clean Architecture)** است.

کد شما باید ماژولار باشد و از کدنویسی اسپاگتی جلوگیری شود.

دیتابیس طراحی‌شده با نام **UniDB** داده‌ها را در قالب **سند (Document)** ذخیره می‌کند.

معماری سیستم (System Architecture) 🏗️

سیستم شامل سه لایه اصلی است و جریان داده از بالا به پایین حرکت می‌کند.

۱. لایه تحلیل (Query Parser) 🔍

- ورودی: رشته متنی خام مانند

"db.students.insertOne(...)"

- وظیفه:

- ✓ توکن‌سازی
- ✓ تشخیص نوع دستور
- ✓ استخراج پارامترها

- خروجی: ایجاد آبجکت **Command**

۲. لایه اجرا (Execution Engine) ⚙️

- وظیفه: اجرای دستورات بر اساس شیء **Command**
 - مدیریت:
 - ♦ صف دستورات (Queue)
 - ♦ پشته تراکنش‌ها (Stack)
 - ارسال دستورات به لایه ذخیره‌سازی (Storage Engine)
-

۳. لایه ذخیره‌سازی (Storage Engine) 💾

- مدیریت مستقیم داده‌ها در RAM
- بدون وابستگی به متن کوئری یا پارسر
- ارائه عملیات‌های پایه:
add, delete, get

ساختار پیشنهادی پروژه (File Structure) 📁

src/

| — main.cpp / Main.java (Entry Point)

| — models/

| | — Student.h (Data Class)

| — parser/

| | — QueryParser.h (Layer 1)

| — engine/

| | — ExecutionEngine.h (Layer 2)

| | — Command.h

| | — TransactionStack.h

| — storage/ (Layer 3)

| | — Collection.h (Interface)

| | — ArrayCollection.h

| | — LinkedListCollection.h

⚠️ **توجه:** تحویل همه کدها در یک فایل باعث کسر نمره خواهد شد.

نیازمندی‌های پیاده‌سازی

لایه ذخیره‌سازی (Storage Engine)

کلاس Collection (اینترفیس)

باید دو نسخه از آن پیاده‌سازی شود:

۱. ArrayCollection

- استفاده از آرایه پویا (Dynamic Array)

- عملکردها:

- > `insertOne` → $O(1)$
- > `deleteOne` → $O(n)$
- > `findById` → $O(n)$
- > `findAll`
- > توابع تجمیعی (`count`, `sum`, `average`)

LinkedListCollection ۲

- پیاده‌سازی لیست پیوندی دوطرفه
- عملیات با تغییر پوینتر انجام می‌شود
- جستجو خطی است
- توابع مشابه نسخه آرایه‌ای

توابع جستجو

- `findAll()`
- `filter(field, value)`

لایه اجرا (Execution Engine)

۱. مدیریت تراکنش‌ها (Stack)

- `beginTransaction()`
 - `rollback()` (بازگشت با پاپ‌کردن پشته)
 - `commit()` (تثبیت)
-

۲. مدیریت صف دستورات (Queue)

- `batch.start` → ورود به حالت دسته‌ای
- `batch.execute` → اجرای ترتیبی صف

لایه تحلیل (Query Parser)

- استفاده از روش‌های ساده رشته‌ای
- تبدیل دستور به شیء **Command**
- نیازی به کامپایلر پیچیده نیست

بارگذاری انبوه داده‌ها (Bulk Load)

```
db.students.import("filename.csv")
```

- خواندن فایل CSV خط‌به‌خط
- تبدیل رکورد به سند
- درج سریع
- فرمت: **id,name,gpa**

نحوه تعامل برنامه (Client Simulation)

♦ عملیات پایه

```
db.students.insertOne({_id: 101, name: "Ali", gpa: 18.5})
```

```
db.students.findById(101)
```

```
db.students.findAll()
```

```
db.students.deleteOne({_id: 101})
```

```
db.students.import("data_50k.csv")
```

♦ جستجو و Aggregation

```
db.students.filter("name", "Ali")
```

```
db.students.count()
```

```
db.students.sum("gpa")
```

```
db.students.average("gpa")
```

تراکنش‌ها ♦

```
db.beginTransaction()
```

```
db.students.insertOne({ ... })
```

```
db.students.deleteOne({ ... })
```

```
db.rollback()
```

```
db.commit()
```

Batch Processing ♦

```
db.batch.start()
```

```
db.students.insertOne(...)
```

```
db.students.deleteOne(...)
```

```
db.batch.execute()
```

بخش تحلیلی (Report)

۱. جدول پیچیدگی زمانی (Big O)

عملیات	Array Collection	LinkedList Collection	دلیل تفاوت
insertOne (آخر)	؟	؟	؟
deleteOne (اول)	؟	؟	؟
deleteOne (وسط)	؟	؟	؟
findById	؟	؟	؟
count	؟	؟	آیا می‌توان آن را $O(1)$ کرد؟

۲. بنچمارک (Benchmark)

با ۵۰,۰۰۰ رکورد:

- حذف ۵۰۰ رکورد از ابتدای لیست
- حذف ۵۰۰ رکورد از انتهای لیست
- جستجوی ۵۰۰ رکورد تصادفی

⚠ **توجه:** نتایج باید روی نمودار رسم شود.

۳. ? سؤالات مفهومی

- چرا در لیست پیوندی، deleteOne(id) زمان بر است؟
- چرا جدا بودن Parser از Storage مفید است؟ (مثلاً برای افزودن SQL)

بخش امتیازی پروژه 🏆

🔥 سطح ۱: دیتابیس تحت شبکه (Networked DB – امتیاز: ۲۰۰)

در این سطح، برنامه باید از حالت Shell کنسولی خارج شده و به یک TCP Server واقعی تبدیل شود.

🌟 الزامات:

- سرور باید روی یک پورت مشخص مثل 8080 گوش دهد.
- تمامی دستورات دیتابیس از طریق سوکت شبکه دریافت شوند.
- یک کلاینت ساده بنویسید که:
 - به سرور وصل شود
 - دستورات را ارسال کند
 - خروجی را دریافت و چاپ کند
- چالش اصلی:
✓ سرور باید بتواند همزمان به چند کلاینت پاسخ دهد (با استفاده از Multi-threading یا Thread Pool)

سطح ۲: ذخیره‌سازی دائمی

(File Persistence – امتیاز: ۲۰۰)

در این سطح، داده‌ها باید از حالت موقت خارج شده و امکان ذخیره‌سازی روی دیسک فراهم شود.

الزامات: ✨

- با اجرای دستور `commit()` باید:
 - کل داده‌های داخل حافظه سریالایز شده
 - در یک فایل (مثلاً `db.unidb`) ذخیره شوند
- با اجرای دوباره برنامه، باید:
 - فایل ذخیره‌شده خوانده شود
 - تمام داده‌ها دوباره داخل حافظه بارگذاری شوند
- می‌توانید از فرمت‌های ساده مثل JSON یا باینری استفاده کنید

📁 سطح ۳: فایل سیستم پیشرفته

(Random Access IO – امتیاز: ۲۵۰)

این مرحله مخصوص افراد حرفه‌ای و علاقه‌مند به طراحی دیتابیس واقعی است.

🌟 الزامات:

- دیگر نباید کل فایل را در هر commit بازنویسی کنید
- باید از تکنیک‌های Random Access IO استفاده کنید:
 - `fseek` در ++C/C
 - `RandomAccessFile` در Java
- هنگام تغییر رکورد:
 - باید فقط همان چند بایت مربوط به رکورد تغییر کند
- هنگام حذف رکورد:
 - مقدار رکورد باید به عنوان Free Space یا Hole علامت‌گذاری شود
 - رکوردهای بعدی می‌توانند روی همان بلاک نوشته شوند

این بخش شبیه‌سازی ساده‌ای از Page Management در دیتابیس‌های واقعی است.

⚠ **توجه:** فقط در صورتی امتیاز بخش‌های امتیازی را دریافت می‌کنید که حداقل ۹۰٪ از امتیاز بخش اصلی پروژه را کسب کرده باشید.
در غیر این صورت، حتی اگر بخش امتیازی را کامل پیاده‌سازی کنید، هیچ امتیاز اضافه‌ای برای شما لحاظ نخواهد شد.

قوانین کلین کد (Clean Code Rules)

(کسر نمره تا ۲۰۰ - نمره)

این بخش اجباری است و رعایت نکردن آن باعث کسر شدید نمره می‌شود. هدف این است که پروژه از یک کد تمرینی ساده تبدیل شود به کدی قابل نگهداری، معماری‌مند، و حرفه‌ای.

🌟 قوانین کلیدی:

۱. معماری لایه‌ای باید کاملاً رعایت شود ✓

- Parser نباید به Storage دسترسی مستقیم داشته باشد
- Storage نباید از وجود دستورها خبر داشته باشد
- Engine نباید فرمت ورودی کاربر را بداند

۲. داشتن ماژول‌های جداگانه برای هر کلاس ✓

کدهای چسبیده به هم یا در یک فایل

۳. نام‌گذاری صحیح ✓

- کلاس‌ها: PascalCase
- توابع و متغیرها: camelCase
- نام‌ها باید معنی‌دار باشند:

بد ✗ : `x, y, arr2`

خوب ✓ : `studentList, transactionStack`

✓ ۴. تابع‌های کوتاه و مینیمال

- تابع نباید طولانی و چندکاره باشد
- حداکثر یک وظیفه مشخص برای هر تابع

✓ ۵. عدم تکرار کد (DRY)

- کپی‌پیست در چند کلاس → کسر نمره

✓ ۶. استفاده از Abstraction و Interface

- مجموعه‌ها باید از طریق Interface مشترک مدیریت شوند
- نباید نوع کالکشن در لایه بالاتر مشخص باشد

✓ ۷. نبودن کدهای کامنت‌شده اضافی

- فقط کامنت‌های مفهومی و حرفه‌ای مجاز هستند.

⚠ **توجه:** این بخش برای اطمینان از تبدیل پروژه شما به یک کد قابل ارائه در رزومه یا گیت‌هاب است.

بارمبندی پروژه (۲۰۰۰ نمره اصلی + ۶۰۰ امتیازی)

Storage Layer – ۸۰۰ .۱

- ۳۰۰ نمره: ArrayCollection
- ۳۰۰ نمره: LinkedListCollection
- ۲۰۰ نمره: توابع جستجو و Aggregation

Execution Engine – ۵۰۰ .۲

- ۳۰۰ نمره: تراکنش‌ها
- ۲۰۰ نمره: صف Batch

Parser – ۳۰۰ .۳

- ۱۵۰ نمره: پارس دستورات
- ۱۵۰ نمره: Import CSV

۴۰۰ .۴ – گزارش فنی

- ۱۵۰ نمره: جدول Big O
- ۱۵۰ نمره: نمودارها
- ۱۰۰ نمره: سؤال‌های مفهومی

۵. ۶۰۰ – امتیازی 🏆

- ۲۰۰ نمره: دیتابیس تحت شبکه
- ۱۵۰ نمره: ذخیره سازی دائمی
- ۲۵۰ نمره: فایل سیستم پیشرفته

۶. (۲۰۰-) – Clean Code 🧠

- معماری لایه ای نادرست
- نام گذاری بد، توابع بزرگ، کد تکراری
- عدم استفاده از Interface/Abstraction مناسب
- ساختاردهی غلط پروژه یا تحویل فایل یک تکه
- کد اسپاگتی و عدم رعایت Clean Architecture